

Avance técnico breve: recuperación alta no implica razonamiento composicional — evaluación de CLIP en Winoground

Niels Victor Pacheco Barrios

MCC225 — Maestría en Ciencias de la Computación — 2026-1

11 de julio de 2026

1. Problema y tarea multimodal

El trabajo evalúa si un modelo *dual-encoder* tipo CLIP, fuerte en recuperación imagen–texto, razona de forma *composicional*. Las modalidades son imagen y texto: la entrada es un par mínimo formado por dos imágenes y dos *captions* que contienen exactamente las mismas palabras en distinto orden, y la salida es una matriz de similitud coseno 2×2 entre cada *caption* y cada imagen. La tarea es de emparejamiento composicional y recuperación (*compositional image–text matching*): acertar exige codificar relaciones espaciales y vinculación atributo–objeto, no solo reconocer conceptos aislados. El conjunto es Winoground (Thrush et al., 2022), con sus 400 ejemplos oficiales. La métrica principal son los tres *scores* oficiales: *text* (elegir la *caption* correcta para ambas imágenes), *image* (elegir la imagen correcta para ambas *captions*) y *group* (acertar ambas condiciones a la vez). El criterio de validación de la hipótesis es que el *group score* supere el azar de $1/6 \approx 0,167$ (el azar no es $1/4$ porque *text* e *image* no son independientes); si no lo supera pese a una recuperación alta, se confirma que retrieval y composición son capacidades distintas.

2. Arquitectura multimodal y comparación

El sujeto de evaluación es un dual-encoder CLIP (OpenCLIP, ViT-B-32/laion2b): dos torres Transformer independientes proyectan imagen y texto a un espacio común, y la comparación es un coseno entre dos embeddings globales L2-normalizados. Se eligió por ser barato, determinista y reproducible en CPU/MPS –solo inferencia–, y porque es justo la familia que sobresale en retrieval y cuya composición queremos poner a prueba. Como contraste conceptual está el *cross-encoder* de fusión profunda (estilo BLIP-2 o MMBT, con atención crossmodal). Las diferencias relevantes: **costo computacional** — el dual-encoder precomputa embeddings y escala a galerías masivas ($O(N)$ comparaciones), mientras la fusión profunda debe reprocesar cada par imagen–texto conjuntamente y no escala a retrieval masivo; **tipo de alineamiento** — tardío y global (*late fusion*, un vector por modalidad) frente a profundo y token-a-token (atención cruzada entre parches visuales y *tokens* textuales); **tipo de error** — el dual-encoder se comporta como *bag-of-concepts*, insensible al orden y a la relación, justo lo que Winoground penaliza, mientras la fusión profunda puede modelar dependencias entre atributos y objetos; **interpretabilidad** — la fusión profunda expone mapas de atención cruzada inspeccionables, mientras el dual-encoder solo entrega una similitud escalar. Para *esta* tarea la fusión profunda es más pertinente en expresividad composicional, pero el dual-encoder es el sujeto correcto para *exhibir* la brecha entre recuperación y composición a bajo costo.

3. Transformer y atención, conectados al modelo

Cada torre es un Transformer: el texto se divide en *tokens* y la imagen en parches, ambos convertidos en *embeddings* a los que se suma una codificación posicional que reintroduce el orden perdido por la permutación-invarianza de la atención. El mecanismo central es la atención producto-punto escalada, $\text{softmax}\left(QK^\top/\sqrt{d}\right)V$, donde cada *token* emite una consulta Q , una clave K y un valor V ; el producto $QK^\top$ mide afinidad entre *tokens*, el factor $1/\sqrt{d}$ evita saturar el *softmax* y la salida es una combinación ponderada de los valores. En *self-attention* Q , K y V provienen de la misma secuencia (los *tokens* de texto se atienden entre sí; los parches de imagen entre sí), mientras en *cross-attention* las consultas de una modalidad atienden a las claves y valores de la otra, habilitando *grounding* explícito parche $\leftrightarrow$ palabra. El costo es $O(n^2)$ en el número de *tokens*, lo que encarece las secuencias largas (una imagen aporta muchos más parches que palabras un *caption*). El punto mecanístico clave: CLIP usa *self-attention* dentro de cada torre pero **no** tiene *cross-attention* entre ellas; imagen

y texto solo se encuentran al final, ya colapsados en un vector por el coseno. Sin interacción token-a-token no hay mecanismo para verificar qué atributo se liga a qué objeto ni qué entidad ejerce una relación, y esa es la razón mecánica por la que la composición cae cerca del azar aunque la recuperación sea alta.

4. Evidencia experimental

La Tabla 1 reúne los resultados sobre los 400 ejemplos oficiales con ViT-B-32/laion2b. El *text score* (0,3475) supera el azar de 0,25, pero el *group score* (0,075) queda por debajo del azar de 0,167 y lejísimos del humano (0,855); en paralelo la recuperación es alta ($R@5=0,667$, $R@10=0,774$). Que *group* $< 1/6$ no significa “peor que aleatorio” en general: es consecuencia de la asimetría *text* $\gg$ *image*, ya que el *group* exige ganar ambas direcciones. El análisis por tag confirma la naturaleza del fallo: la categoría *Relation* es la peor (*group*= 0,047, $n = 233$), seguida de *Object* (0,085, $n = 141$) y *Both* (0,269, $n = 26$); son fallos de *vinculación* y no de reconocimiento. El scorer quedó validado contra los *scores* oficiales de CLIP del propio dataset (`clip.jsonl`), reproduciendo *text*= 0,3075, *image*= 0,105, *group*= 0,080. La comparación de tres *checkpoints* no muestra tendencia monótona con el tamaño (*group*: 0,075 en B-32/laion2b, 0,0725 en B-16/datacomp_xl, 0,085 en L-14/openai), de modo que escalar no resuelve la composición. Las figuras `recall_vs_group.png`, `by_tag.png`, `scores_vs_chance.png`, `blindness.png` y `checkpoint_comparison.png` (en `outputs/figures/`) documentan gráficamente estos hallazgos.

Cuadro 1: Winoground oficial ($N = 400$), OpenCLIP ViT-B-32/laion2b. Valores exactos de `outputs/metrics/`.

Métrica	Modelo	Azar	Humano
Text score	0,3475	0,250	0,895
Image score	0,110	0,250	0,885
Group score	0,075	0,167	0,855
<i>Recuperación (texto→imagen, galería de 800)</i>			
R@1 / R@5 / R@10	0,304 / 0,667 / 0,774		
<i>Group score por tag (collapsed)</i>			
Relation ($n=233$)	0,047		
Object ($n=141$)	0,085		
Both ($n=26$)	0,269		

5. Análisis de errores y confiabilidad

Los casos fallidos están dominados por *Relation*: el modelo reconoce las entidades pero no resuelve quién ejerce la relación ni qué atributo se liga a qué objeto. La *prueba de ceguera* (permutar las imágenes) actúa como evidencia de explicabilidad: el desempeño real (0,3475/0,110/0,075) cae de forma marcada con imágenes permutadas (0,135/0,035/0,015), lo que confirma que el modelo *sí* usa el contenido visual –su límite es composicional, no perceptivo. En cuanto a confiabilidad, el sistema es *parcialmente confiable*, solo en condiciones controladas: adecuado para recuperación y emparejamiento grueso, pero no para decisiones que dependan de relaciones o vinculación fina. El riesgo técnico dominante es la **composición** (falta de fusión crossmodal), y entre los sesgos posibles están el desbalance de distribución del preentrenamiento LAION, el carácter OOD del set curado sintético para CLIP, y la sensibilidad de la métrica a empates y normalización; además, el *group score* mezcla fallo composicional con la ambigüedad intrínseca de algunos ítems (Diwan et al., 2022).

6. Plan de cierre

Antes de la defensa final: (i) ya se probó un *re-ranker-lite* validado por folds (*group* $\approx 0,11/0,01/0,03/0,06$), por lo que el paso de cierre es evaluar un *cross-encoder* profundo real (C5) sobre Winoground para cuantificar la ganancia composicional atribuible a la atención cruzada; (ii) añadir un re-ranking con interacción cruzada (C6) sobre los candidatos recuperados por el dual-encoder; (iii) ampliar prompts y *checkpoints* y correr el intervalo de confianza *bootstrap* en todas las condiciones; y (iv) versionar los embeddings con DVC para asegurar la reproducibilidad extremo a extremo.

Declaración de uso de IA generativa. Empleé un asistente de IA generativa (Claude) para redactar y estructurar este avance a partir de mis resultados y notas; las mediciones, el código y las conclusiones son propios y fueron verificados contra `outputs/metrics/`.

Referencias. Thrush et al. (2022), *Winoground*, CVPR. Diwan et al. (2022), *Why is Winoground Hard?*, EMNLP. Radford et al. (2021), *CLIP*, ICML. Agarwal et al. (2021), *Evaluating CLIP*.