

Winoground: evaluar CLIP en razonamiento composicional

El retrieval alto no implica composición

Niels Victor Pacheco Barrios

Maestría en Ciencias de la Computación · MCC225 — IA Generativa y Multimodal · 2026-1
Segunda Exposición Académica — Trabajo integrador

1 · Trabajo integrador: modalidades y tarea

Estudiante: Niels Victor Pacheco Barrios · **Curso:** MCC225 (2026-1)

Trabajo: *Winoground / Evaluating CLIP* — evaluación de un dual-encoder CLIP.

Modalidades

- **Imagen** (torre visual, ViT).
- **Texto** (torre de lenguaje, transformer).

Tarea principal

- Emparejamiento composicional imagen–texto.
- Recuperación (retrieval) sobre pares mínimos.

Tesis: un *Recall@K* alto **no** implica razonamiento composicional.

2 · Problema, motivación, datos y criterio de éxito

Problema. ¿CLIP *entiende* la escena o solo *empareja* conceptos?

Motivación. Winoground usa *pares mínimos*: 2 imágenes y 2 captions con las **mismas palabras en distinto orden**. Distinguirlos exige saber *quién hace qué a quién*, no reconocer objetos sueltos.

Datos disponibles

- Winoground: **400** pares mínimos.
- Etiquetas: *Object, Relation, Both*.

Criterio de éxito

- **group score** $>$ azar
 $= 1/6 \approx \mathbf{0,167}$.
- Referencia humana $\approx 0,855$.

El azar del group es $1/6$ (no $1/16$): de las $4! = 24$ ordenaciones de las 4 similitudes, solo 4 aciertan.

3 . Arquitectura: dual-encoder CLIP vs. cross-encoder

	Dual-encoder (CLIP)	Cross-encoder (BLIP/fusión)
Alineamiento	tardío, 1 vector global/modalidad	profundo, token-a-token (cross-attention)
Costo	barato, escala a retrieval masivo	caro, no escala a galería grande
Tipo de error	falla composición (orden/relación)	mejor grounding, mejor composición
Interpretab.	solo similitud coseno global	mapas de atención cruzada
Pertinencia	elegido : reproducible en CPU/MPS	propuesto como contraste/mejora

Decisión (ADR 0001): evaluar el dual-encoder (motor OpenCLIP, C10) como sujeto principal — ligero, determinista, defendible — y usar la fusión profunda (C5) / atención crossmodal (C8) como *marco de contraste* que explica *por qué* el dual-encoder falla la composición.

4 · Transformer y atención, conectados al modelo

Del texto/imagen a tokens. Entrada $\rightarrow$ tokens $\rightarrow$ *embeddings* + codificación de *posición* (imagen: parches ViT; texto: subpalabras).

Atención producto-punto escalada:

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d}}\right) V$$

Q (consulta), K (clave), V (valor); pesos = afinidad token-token.

Costo $O(n^2)$ en la longitud de secuencia n .

Self- vs cross-attention.

- *Self*: tokens atienden dentro de **una** modalidad.
- *Cross*: tokens de imagen atienden a los de texto (y viceversa) $\Rightarrow$ grounding.


En CLIP (dual-encoder): solo **self-attention** dentro de cada torre; los tokens de imagen y de texto **nunca** interactúan directamente — cada modalidad colapsa a un vector global antes de compararse.

Sin cross-attention $\Rightarrow$ sin alineamiento token-a-token $\Rightarrow$ composición débil.

5 · Evidencia experimental (motor C10 / pipeline Winoground)


Métrica	Valor	Azar
text score	0.3475	0.25
image score	0.110	0.25
group score	0.075	0.167
R@5 (t2i)	0.667	—
R@10 (t2i)	0.774	—

ViT-B-32/laion2b, $N = 400$. IC bootstrap 95 % del group [0,05, 0,10]: **entero por debajo del azar**. Humano $\approx 0,855$.



Retrieval alto ($R@10=0,774$) con **group muy por debajo del azar** (0,075 vs 0,167): retrieval $\neq$ composición.

6 · Análisis de errores: aciertos, fallos y límites




Correctos. El modelo detecta bien objetos $\Rightarrow$ retrieval y text score sobre el azar.

Fallos por tag (group):

- **Relation:** 0.047 ($n=233$) — peor: fallo de vinculación (quién con quién).
- **Object:** 0.085 ($n=141$).
- **Both:** 0.269 ($n=26$) — las dos imágenes difieren más.

Limitaciones. El group bajo mezcla fallo composicional con ítems ambiguos (Diwan et al.); métricas estrictas sensibles a empates.

7 · Actividad 5: confiabilidad, explicabilidad, robustez, riesgos



Confiabilidad. Scorer validado contra los scores oficiales clip.jsonl (0.3075/0.105/0.08): coincidencia exacta. IC bootstrap reportados.

Explicabilidad (prueba de ceguera). Permuto las imágenes y recalculo: los scores caen de 0,3475/0,110/0,075 a 0,135/0,035/0,015 ($\approx$ azar). $\Rightarrow$ el modelo **sí usa la imagen**; su límite es *composicional*, no perceptivo.

Robustez. Escalar tamaño/datos no ayuda: group 0,075 $\rightarrow$ 0,073 $\rightarrow$ 0,085; el text incluso baja (0,3475 $\rightarrow$ 0,2975 $\rightarrow$ 0,2875).

Riesgos/sesgos. R@K alto puede *sobrevender* comprensión; sesgo de bolsa-de-conceptos ignora orden y relaciones.

8 . Plan de cierre hacia la defensa final

Por implementar

- Evaluar un **cross-encoder profundo real** (BLIP/MMBT, C5), más allá del *re-ranker-lite* ya probado (§12 del notebook): interacción cruzada real (C6).
- Versionar embeddings (DVC) para reproducibilidad total de datos.

Por validar

- Ampliar a más prompts / *prompt ensembles* y más checkpoints (C10).
- Confirmar estabilidad de los IC con más rondas de bootstrap.

Por corregir / matizar

- Separar fallo composicional de ítems ambiguos (Diwan et al.).
- El set curado offline es un *proxy*; priorizar acceso al benchmark gated.

Hipótesis abierta: que un cross-encoder *profundo* cierre la brecha composicional que el re-ranker-lite no cerró.

Trabajo individual. Se usó asistencia de IA generativa; las definiciones de métrica se verificaron contra el paper de Winoground y el scorer oficial.